
Um Modelo Preditivo de Fatalidade em Acidentes Aeronáuticos no Brasil: Random Forest Aplicado a Dados da ANAC

Flávio Ulisses Sales da Silva

Departamento de Estatística (DE), Universidade Federal de Pernambuco, Recife, Brasil

Email: flavio.usilva@ufpe.br |

1. Introdução

A segurança da aviação civil é uma das áreas mais críticas dentro da gestão de riscos em transportes. Apesar dos avanços tecnológicos e regulatórios observados nas últimas décadas, acidentes aeronáuticos continuam a ocorrer e frequentemente resultam em perdas humanas irreparáveis. No Brasil, o Centro de Investigação e Prevenção de Acidentes Aeronáuticos (CENIPA) é o órgão responsável por investigar ocorrências aeronáuticas em território nacional. Os dados abertos utilizados neste estudo foram obtidos da Agência Nacional de Aviação Civil (ANAC), que disponibiliza um dos acervos mais completos e acessíveis do país sobre o tema (ANAC, 2023).

A capacidade de prever, com antecedência ou em tempo real, se um acidente aeronáutico resultará em vítimas fatais representa um avanço significativo tanto para a investigação forense quanto para a definição de políticas preventivas. Identificar os fatores que mais contribuem para desfechos letais permite que autoridades e operadores concentrem esforços nos pontos de maior vulnerabilidade, alocando recursos de forma mais eficiente e fundamentando ações regulatórias com base em evidências (Caetano, 2023; Ramadhan et al., 2025).

Dentro desse contexto, técnicas de aprendizado de máquina (*machine learning*) têm ganhado crescente relevância na análise de dados de acidentes de transporte. Ao contrário de abordagens estatísticas tradicionais, os algoritmos de *machine learning* são capazes de capturar relações complexas e não-lineares entre variáveis, lidar com grandes volumes de dados e gerar modelos preditivos com alta capacidade de generalização (Baugh, 2020; Siow, 2025).

1.1 Revisão da Literatura

A literatura sobre análise de acidentes aeronáuticos por meio de métodos quantitativos tem crescido de forma expressiva nas últimas décadas. Breiman (2001) introduziu o algoritmo Random Forest, um método de aprendizado em conjunto baseado em múltiplas árvores de decisão, demonstrando sua superioridade frente a outros classificadores em termos de acurácia e robustez ao ruído. Desde então, o algoritmo passou a ser amplamente adotado em problemas de classificação em contextos de segurança, inclusive na aviação.

No campo do tratamento de dados desbalanceados — problema recorrente em bases de acidentes, onde eventos fatais representam a classe minoritária — Chawla et al. (2002) propuseram a técnica SMOTE (*Synthetic Minority Oversampling Technique*), que gera exemplos sintéticos da classe minoritária por interpolação entre instâncias reais. A técnica tornou-se referência na literatura de aprendizado de máquina aplicado a eventos raros, sendo amplamente utilizada em estudos subsequentes.

Baugh (2020) conduziu um estudo preditivo sobre acidentes fatais na aviação geral utilizando dados do *National Transportation Safety Board* (NTSB) dos Estados Unidos. O autor combinou técnicas de mineração de texto com variáveis estruturadas, testando cinco algoritmos — incluindo Random Forest e Gradient Boosting — e concluindo que variáveis textuais extraídas dos relatórios de acidente possuem alto poder preditivo sobre a gravidade do desfecho.

Caetano (2023) investigou a previsão de acidentes e incidentes aeronáuticos no Brasil combinando dados operacionais do CENIPA com dados meteorológicos de estações automáticas. O estudo utilizou 6.188 ocorrências registradas entre 2010 e 2021 e aplicou múltiplos classificadores, obtendo acurácia de 96,20% com o Random Forest. Os resultados indicam que variáveis como peso máximo de decolagem, modelo da aeronave e direção do vento estão entre os principais preditores de ocorrências aeronáuticas.

Madeira et al. (2021) aplicaram técnicas de aprendizado de máquina e processamento de linguagem natural sobre relatórios de incidentes aeronáuticos para identificar fatores humanos associados a falhas operacionais. O estudo, publicado na revista *Aerospace*, reforça a relevância de abordagens baseadas em dados para a gestão proativa de segurança na aviação, destacando que modelos preditivos podem antecipar condições de risco antes que resultem em acidentes.

Siow (2025) propôs uma abordagem prática para classificação de ocorrências aeronáuticas com modelos supervisionados, avaliando cinco algoritmos — incluindo Random Forest, SVM e XGBoost — sobre um conjunto de 475 relatórios de investigação. O Random Forest apresentou o melhor desempenho geral (F1-score = 0,78), e o estudo explorou ainda o efeito da aplicação do SMOTE sobre o balanceamento de classes, observando que os ganhos variam conforme o algoritmo e a natureza dos dados.

Ramadhan et al. (2025) realizaram uma análise abrangente de 75 anos de registros globais de acidentes aéreos, utilizando SVM, Random Forest e Naive Bayes para prever a ocorrência de fatalidades. O SVM obteve o melhor F1-score (79,85%), enquanto o Random Forest alcançou acurácias próximas a 80%. Os autores identificam que a fase de voo e o tipo de serviço prestado são variáveis de forte influência sobre o desfecho fatal, e destacam a estagnação nos avanços de segurança observada desde o final dos anos 1990 como motivação para abordagens orientadas por dados.

İnan e Gökmen İnan (2022) analisaram 220 dos acidentes aéreos mais fatais da história da aviação civil — aqueles com mais de 100 passageiros mortos — utilizando regressão logística, análise discriminante e algoritmos de aprendizado de máquina para classificar a taxa de sobrevivência. O estudo, publicado na revista *OPSEARCH*, identificou que a fase do voo, o tipo de aeronave e o fator causal primário (humano, técnico ou sabotagem) são determinantes significativos do desfecho fatal, e demonstrou que os modelos de aprendizado de máquina apresentam robustez superior frente às abordagens estatísticas tradicionais.

Omrani et al. (2024) realizaram uma avaliação comparativa de múltiplos algoritmos de aprendizado de máquina — incluindo ANN, árvores de decisão e SVM — aplicados a bases de dados de acidentes aeronáuticos dos Estados Unidos, Canadá e Austrália, cobrindo o período

de 2008 a 2023. O estudo, publicado no *Journal of Air Transport Management*, constatou que modelos treinados separadamente por país apresentam melhor desempenho do que modelos unificados, o que reforça a importância de desenvolver modelos preditivos contextualizados para realidades nacionais específicas — tal como proposto no presente estudo para o caso brasileiro.

Em conjunto, os estudos revisados evidenciam que o Random Forest é um dos algoritmos mais consistentes para classificação de acidentes aeronáuticos, que o desbalanceamento de classes é um desafio central nesse tipo de problema, e que há espaço para contribuições relevantes no contexto da aviação civil brasileira — especialmente utilizando dados abertos da ANAC, ainda pouco explorados com modelos preditivos de aprendizado de máquina.

1.2 Problema de Pesquisa e Objetivos

Apesar da relevância do tema e do crescimento da literatura internacional, há uma lacuna expressiva em estudos que apliquem modelos preditivos de aprendizado de máquina sobre dados de acidentes aeronáuticos exclusivamente brasileiros, considerando as particularidades do espaço aéreo, da frota e do perfil de operadores do país. A ausência de modelos voltados ao contexto nacional limita a capacidade das autoridades brasileiras de adotar uma gestão de segurança orientada por dados.

Diante disso, este artigo busca responder à seguinte pergunta de pesquisa: *É possível, a partir das informações disponibilizadas pela ANAC sobre ocorrências aeronáuticas no Brasil, construir um modelo preditivo capaz de identificar, com acurácia aceitável, se um acidente resultará em fatalidade?*

O objetivo geral do estudo é desenvolver e avaliar um modelo de classificação binária — com base no algoritmo Random Forest — para prever a ocorrência de fatalidades em acidentes aeronáuticos brasileiros. Como objetivos específicos, destacam-se: (i) realizar o tratamento e engenharia de variáveis sobre os dados brutos da ANAC; (ii) lidar adequadamente com o desbalanceamento de classes mediante a técnica de *class_weight* balanceado; (iii) avaliar o modelo por meio de métricas como F1-score, ROC-AUC e PR-AUC; e (iv) analisar a importância relativa das variáveis preditoras.

1.3 Justificativa

A necessidade deste estudo se fundamenta tanto na dimensão social quanto na científica. Do ponto de vista social, a previsão de fatalidades em acidentes aeronáuticos pode subsidiar políticas de prevenção mais eficazes, direcionando atenção regulatória às combinações de fatores de maior risco. Do ponto de vista científico, o trabalho contribui para a literatura de aprendizado de máquina aplicado à segurança do transporte, especialmente no que diz respeito ao contexto da aviação civil brasileira, ainda pouco explorado quantitativamente.

Adicionalmente, o uso de dados abertos da ANAC reforça o potencial de replicabilidade e extensão da pesquisa, favorecendo o desenvolvimento de estudos comparativos e a construção de modelos ainda mais robustos no futuro. Ao contrário de estudos que dependem de bases proprietárias ou restritas, a utilização de dados públicos amplia o alcance científico do trabalho e facilita sua reprodução por outros pesquisadores.

1.4 Organização do Artigo

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve a base de dados utilizada e apresenta a metodologia adotada, incluindo as etapas de pré-processamento, engenharia de variáveis e treinamento do modelo. A Seção 3 apresenta e discute os resultados obtidos, com ênfase nas métricas de desempenho e na análise de importância das variáveis. Por fim, a Seção 4 reúne as conclusões do estudo, suas limitações e sugestões para pesquisas futuras. As referências bibliográficas encerram o documento.

2. Metodologia

2.1 Fonte e Descrição dos Dados

Os dados utilizados neste estudo foram obtidos do acervo de dados abertos da Agência Nacional de Aviação Civil (ANAC), por meio do arquivo de ocorrências aeronáuticas disponibilizado publicamente pela agência (ANAC, 2023). A base de dados reúne registros de acidentes e incidentes aeronáuticos ocorridos no território brasileiro, com informações coletadas e sistematizadas pelo Centro de Investigação e Prevenção de Acidentes Aeronáuticos (CENIPA). O arquivo foi importado no formato CSV com separador ponto e vírgula (“;”), utilizando a biblioteca *pandas* em ambiente Python (Google Colab).

A base contém uma ampla gama de atributos por ocorrência, abrangendo informações temporais (data e hora do acidente), geográficas (região e unidade federativa), operacionais (tipo de operação, fase da operação, tipo de ocorrência), características da aeronave (peso máximo de decolagem — PMD, tipo, categoria, descrição e aeródromo de origem) e informações sobre as vítimas (lesões fatais, graves, leves e ileas, discriminadas por tripulantes, passageiros e terceiros). Colunas com proporção de valores ausentes superior a 70% foram removidas por não oferecerem informação suficiente para o treinamento do modelo.

2.2 Variável Resposta

A variável resposta do modelo é *Fatalidade*, uma variável binária construída a partir das colunas de lesões fatais disponíveis na base de dados. Especificamente, a variável assume o valor 1 quando a soma das colunas *Lesoes_Fatais_Tripulantes*, *Lesoes_Fatais_Passageiros* e *Lesoes_Fatais_Terceiros* é maior que zero, e 0 caso contrário. Após a criação da variável resposta, todas as colunas de lesões (fatais, graves, leves e ileas) foram removidas do conjunto de preditores, evitando o vazamento de informação (*data leakage*). Da mesma forma, a variável *Classificacao_da_Ocorrencia* foi excluída por representar uma síntese da gravidade do evento, o que configuraria uma variável oculta que revelaria diretamente o desfecho.

2.3 Engenharia de Variáveis

A partir das variáveis brutas da base de dados, foram construídas novas features com o objetivo de enriquecer a capacidade preditiva do modelo. Primeiramente, a variável de hora da ocorrência, originalmente armazenada como texto, foi convertida para o formato numérico e, a partir dela, derivou-se a variável *periodo*, que classifica o turno do acidente em manhã (06h–11h59), tarde (12h–17h59) ou noite (18h–05h59). Da data da ocorrência, foram extraídas as

variáveis *trimestre* (1º ao 4º trimestre do ano) e *decada* (década de ocorrência do acidente), para capturar possíveis tendências temporais de longo prazo.

Com relação ao porte da aeronave, o Peso Máximo de Decolagem (PMD) foi utilizado para criar a variável categórica *Porte*, com os seguintes estratos: *Indeterminado* ($PMD \leq 0$), *leve* (até 5.700 kg), *medio* (5.701–15.000 kg), *grande* (15.001–50.000 kg) e *muito_grande* (acima de 50.000 kg). Os limiares adotados são consistentes com os critérios de classificação operacional previstos no Regulamento Brasileiro da Aviação Civil (RBAC), que estabelece 5.700 kg como limite superior para aeronaves de pequeno porte da aviação geral, e são amplamente utilizados na literatura de segurança aeronáutica nacional (Caetano, 2023). Adicionalmente, dado que a distribuição do PMD apresenta dispersão extrema — com aproximadamente 95% dos valores abaixo de 8.000 kg, mas com observações atingindo 30.000–50.000 kg —, optou-se por incluir também a transformação logarítmica $PMD_log = \log(1 + PMD)$, permitindo ao modelo selecionar a forma mais informativa de representação da massa da aeronave.

Dois agrupamentos adicionais foram construídos a partir da variável *Fase_da_Operacao*. A variável *fase_agrupada* consolidou as fases originais em quatro categorias: *Chegada* (pouso, aproximação e corrida após pouso), *Saida* (decolagem, subida e manobra), *Cruzeiro* (em rota e cruzeiro) e *Outros* (especializada e indeterminada). Paralelamente, a variável binária *critico* indica se a fase de operação é considerada crítica (valor 1), ou seja, aquelas com maior margem para erro humano e maior propensão a acidentes: pouso, decolagem, corrida após pouso, subida e aproximação. As demais fases recebem o valor 0.

2.4 Pré-Processamento dos Dados

O tratamento dos valores ausentes seguiu uma abordagem diferenciada por tipo de variável. Para as variáveis categóricas com proporção de dados faltantes inferior a 30% — incluindo *Descricao_do_Tipo*, *Regiao*, *Tipo_de_Ocorrencia*, *Operacao* e *periodo* — os valores ausentes foram substituídos pela categoria “Desconhecido”. Essa estratégia foi adotada com base na premissa de que a ausência de informação pode em si ser informativa: em situações de emergência ou limitações técnicas da aeronave, determinados registros podem não ter sido coletados, tornando o próprio valor ausente um sinal relevante para o modelo.

Para reduzir a dimensionalidade e evitar a criação de variáveis dummies para categorias com frequência muito baixa, as categorias com ocorrência inferior a 3% do total foram agrupadas sob o rótulo “OUTROS” em cada variável categórica (com exceção de *Porte*, cujas categorias são ordinais e fixas). Em seguida, todas as variáveis categóricas foram codificadas via *One-Hot Encoding* com exclusão da primeira categoria (*drop_first=True*), gerando matrizes binárias de dimensão (n-1) para evitar multicolinearidade perfeita entre as dummies.

2.5 Modelo Empregado e Formulação Matemática

O modelo adotado é o Random Forest (Breiman, 2001), um método de aprendizado em conjunto baseado na combinação de múltiplas árvores de decisão treinadas de forma independente sobre amostras aleatórias do conjunto de treinamento. Dado um conjunto de treinamento com n observações e p variáveis preditoras, o algoritmo constrói B árvores de decisão, cada uma treinada sobre uma amostra *bootstrap* do conjunto de treinamento e utilizando apenas um subconjunto aleatório de m variáveis (*max_features*) em cada divisão de

nó. A predição final para uma nova observação é determinada por votação majoritária das B árvores:

$$\hat{y}(x) = \text{modo} \{ h_1(x), h_2(x), \dots, h_B(x) \}$$

onde $h_1(x), \dots, h_B(x)$ são as predições individuais de cada árvore para a observação x . Neste estudo, o algoritmo foi configurado com os seguintes hiperparâmetros: 400 árvores ($n_estimators=400$), profundidade máxima de 15 ($max_depth=15$), mínimo de 10 amostras para divisão de nó ($min_samples_split=10$), mínimo de 3 amostras por folha ($min_samples_leaf=3$) e seleção aleatória de features em escala logarítmica ($max_features='log2'$). A seleção do Random Forest como algoritmo principal foi embasada tanto pela literatura especializada — que o aponta consistentemente como um dos classificadores mais robustos em dados de segurança aeronáutica (Caetano, 2023; Ramadhan et al., 2025) — quanto por comparação empírica direta com o XGBoost, cujos resultados são apresentados na Seção 3.2.

2.6 Desbalanceamento de Classes e Estratégia de Tratamento

Bases de dados de acidentes aeronáuticos são tipicamente caracterizadas por acentuado desbalanceamento de classes: eventos com fatalidade constituem a classe minoritária, enquanto a maioria das ocorrências não resulta em vítimas fatais. Para lidar com esse problema, o modelo foi treinado com o parâmetro *class_weight* = 'balanced', que ajusta automaticamente os pesos das classes de forma inversamente proporcional à sua frequência no conjunto de treinamento. Essa abordagem foi preferida em relação ao SMOTE (*Synthetic Minority Oversampling Technique*) por ser mais direta, sem introduzir amostras sintéticas que possam distorcer a distribuição dos dados originais. A divisão do conjunto de dados em treinamento (78%) e teste (22%) foi realizada com estratificação pela variável resposta (*stratify=y*), garantindo que a proporção entre as classes seja mantida em ambas as partições.

2.7 Métricas de Avaliação

Dado o desbalanceamento da variável resposta, a acurácia global não é uma métrica adequada para avaliar o desempenho do modelo. Por isso, adotaram-se as seguintes métricas principais: o F1-score, que representa a média harmônica entre precisão e recall e é especialmente indicada para classes desbalanceadas; o ROC-AUC (*Area Under the Receiver Operating Characteristic Curve*), que mensura a capacidade discriminatória do modelo ao longo de todos os limiares de classificação; e o PR-AUC (*Area Under the Precision-Recall Curve*), cujo valor base (*baseline*) corresponde à proporção da classe positiva na base de dados, tornando-a particularmente informativa em cenários de desequilíbrio severo entre classes.

O limiar de classificação (*threshold*) foi ajustado a partir da análise da curva Precision-Recall. Foram explorados os valores de 0,39, 0,45 e 0,51, resultando em diferentes compromissos entre precisão e revocação. O *threshold* de 0,45 foi adotado como referência principal por oferecer equilíbrio adequado entre identificar o maior número possível de eventos fatais (alto recall = 0,82) e manter precisão aceitável (0,41), resultando em F1-score de 0,54. A escolha final depende do objetivo da aplicação: contextos de triagem preventiva demandam maior recall, enquanto contextos de alocação de recursos priorizam precisão.

3. Resultados

3.1 Estatísticas Descritivas da Variável-Alvo

A base de dados utilizada neste estudo contém 5.158 ocorrências aeronáuticas registradas no Brasil. Após a construção da variável resposta *Fatalidade*, verificou-se que 835 ocorrências (16,6%) resultaram em pelo menos uma vítima fatal, enquanto as 4.186 restantes (83,4%) não apresentaram fatalidades. Esse acentuado desbalanceamento entre as classes — onde eventos fatais representam a minoria — justifica a adoção do parâmetro *class_weight='balanced'* no treinamento do modelo e o uso de métricas como F1-score e PR-AUC, que são mais sensíveis ao desempenho na classe minoritária do que a acurácia global.




Figura 1. Distribuição da variável-alvo Fatalidade na base de dados (n = 5.158).

3.2 Desempenho do Modelo e Comparação de Algoritmos

O Random Forest e o XGBoost foram avaliados sobre o conjunto de teste (22% dos dados, n = 1.105 ocorrências), com estratificação pela variável resposta. Para ambos os modelos, o limiar de classificação (*threshold*) foi ajustado a partir da análise da curva Precision-Recall, tendo sido explorados os valores de 0,39, 0,45 e 0,51. As Tabelas 1 e 2 apresentam as métricas obtidas por cada algoritmo.

Tabela 1. Comparativo de desempenho por threshold — Random Forest (classe positiva: Fatalidade = 1).

Threshold	Precision	Recall	F1-score
0,39	0,38	0,87	0,53
0,45 *	0,41	0,82	0,54
0,51	0,44	0,74	0,55

* Threshold de referência adotado neste estudo. ROC-AUC = 0,872; PR-AUC = 0,530; Baseline PR = 0,178.

O threshold de 0,45 foi selecionado como referência principal por oferecer o melhor equilíbrio entre identificar o maior número possível de eventos fatais e manter uma precisão aceitável. Com esse limiar, o modelo apresentou Recall = 0,82, indicando que 82% dos acidentes fatais foram corretamente identificados, e Precision = 0,41, significando que 41% das alertas emitidas correspondem a casos verdadeiramente fatais. O ROC-AUC de 0,872 demonstra forte capacidade discriminatória global do modelo, enquanto o PR-AUC de 0,530 — substancialmente superior ao *baseline* de 0,178 (proporção da classe positiva) — confirma que o modelo agrega informação preditiva relevante mesmo diante do severo desbalanceamento de classes.

Para embasar empiricamente a seleção do Random Forest como algoritmo principal, o modelo foi comparado ao XGBoost, treinado com otimização de hiperparâmetros via *RandomizedSearchCV*. A Tabela 2 apresenta as métricas do XGBoost nos mesmos *thresholds* avaliados.

Tabela 2. Comparativo de desempenho por threshold — XGBoost (classe positiva: Fatalidade = 1).

Threshold	Precision	Recall	F1-score
0,39	0,33	0,90	0,48
0,45 *	0,37	0,86	0,52
0,51	0,41	0,82	0,54

* Threshold de referência. ROC-AUC = 0,8507; Baseline PR = 0,178.

A comparação entre os dois modelos no *threshold* de referência de 0,45 evidencia a superioridade do Random Forest em termos de Precision (0,41 vs. 0,37; +10,8%) e F1-score (0,54 vs. 0,52; +3,8%), ao passo que o XGBoost apresentou Recall marginalmente superior (0,86 vs. 0,82; +4,9%). Em contexto de triagem preventiva, onde o balanço global entre precisão e revocação é prioritário — e não apenas a maximização do Recall — o Random Forest revelou-se mais adequado. Além disso, o algoritmo oferece maior interpretabilidade por meio da análise de importância de variáveis (MDI), aspecto relevante para a compreensão dos fatores associados a desfechos fatais. Esses resultados corroboram os achados de Caetano (2023) e Ramadhan et al. (2025), que também identificaram o Random Forest como o algoritmo de melhor desempenho geral para dados aeronáuticos.

3.3 Matriz de Confusão

A Figura 2 apresenta a matriz de confusão do modelo com threshold de 0,45. Das 184 ocorrências fatais no conjunto de teste, 150 foram corretamente classificadas (verdadeiros positivos) e 34 foram erroneamente classificadas como não fatais (falsos negativos). Das 921 ocorrências não fatais, 706 foram corretamente identificadas (verdadeiros negativos) e 215 foram incorretamente sinalizadas como fatais (falsos positivos). Em contextos de triagem preventiva, minimizar os falsos negativos — acidentes fatais não identificados — é prioritário, o que justifica a adoção de um threshold mais baixo e o consequente aumento do recall.




Figura 2. Matriz de confusão do modelo Random Forest (threshold = 0,45).

3.4 Curva Precision-Recall

A Figura 3 apresenta a curva Precision-Recall do modelo, com $PR-AUC = 0,530$ e $baseline = 0,178$. A curva apresenta descida consistente e progressiva, sem colapso brusco, o que indica estabilidade no tradeoff entre precisão e revocação ao longo de diferentes limiares. O PR-AUC é aproximadamente três vezes superior ao *baseline* aleatório, confirmando a utilidade preditiva do modelo mesmo em cenário de forte desbalanceamento. Esse resultado é consistente com achados de estudos recentes aplicados a dados aeronáuticos internacionais, como Siow (2025) e Ramadhan et al. (2025), que reportaram PR-AUC e F1-scores no mesmo intervalo para o algoritmo Random Forest.




Figura 3. Curva Precision-Recall do modelo ($PR-AUC = 0,530$; $Baseline = 0,178$).

3.5 Distribuição das Probabilidades Preditas

A Figura 4 ilustra a distribuição das probabilidades preditas pelo modelo, separadas por classe real. Observa-se que a maior parte das ocorrências sem fatalidade (classe 0) concentra-se nas faixas de probabilidade mais baixas (0,0–0,3), enquanto os eventos fatais (classe 1) apresentam distribuição mais dispersa e com massa significativa acima do threshold de 0,45. Essa separação, ainda que imperfeita, evidencia a capacidade discriminatória do modelo: a zona de sobreposição entre as duas distribuições reflete a complexidade inerente ao problema,

uma vez que muitos acidentes fatais e não fatais compartilham características operacionais similares.




Figura 4. Distribuição das probabilidades preditas por classe real (threshold = 0,45).

3.6 Importância das Variáveis Predictoras

A análise de importância das variáveis fornece informações sobre a contribuição relativa de cada preditor para as decisões do modelo. No algoritmo Random Forest, essa métrica é calculada com base na redução média de impureza (*Mean Decrease in Impurity* — MDI) proporcionada por cada variável ao longo de todas as árvores da floresta. A Figura 5 apresenta as dez variáveis de maior poder preditivo identificadas pelo modelo. O peso máximo de decolagem em escala logarítmica (PMD_log) e o PMD original emergem como as variáveis de maior importância, refletindo que o porte da aeronave é o fator mais determinante para a ocorrência de desfechos fatais. Em seguida, destacam-se variáveis relacionadas ao tipo de ocorrência: a Perda de Controle em Voo (LOC-I) e a Perda de Controle em Voo (por descrição do tipo) figuram entre os preditores mais relevantes, assim como a Excursão de Pista. A variável binária que indica se a fase de operação é crítica (Ocorrência Crítica) também aparece entre as dez mais influentes, reforçando a importância do momento operacional do voo. Completam o top 10 a categoria de Voo Privado, o Tipo Desconhecido (UNK), a Ocorrência (RE) e a Perda de Controle no Solo. Esses resultados são consistentes com os achados de Caetano (2023) e Ramadhan et al. (2025), que identificaram peso da aeronave, tipo de ocorrência e fase do voo como preditores de elevado poder discriminatório.




Figura 5. As dez variáveis de maior importância no modelo Random Forest (MDI).

Com o objetivo de aprofundar a interpretação dos preditores mais influentes, foram realizadas análises exploratórias individuais para três das variáveis de maior relevância no modelo: PMD (porte da aeronave), Fase Crítica e Tipo de Ocorrência.

Em relação ao peso máximo de decolagem (PMD), a análise descritiva por grupo de desfecho revelou que os acidentes com fatalidade apresentam, em média, aeronaves de menor porte do que os acidentes sem fatalidade. A distribuição do $\log(\text{PMD})$ para acidentes fatais é mais concentrada e apresenta mediana significativamente inferior à distribuição dos acidentes não fatais, indicando que aeronaves leves e de pequeno porte são proporcionalmente mais representadas entre os eventos com vítimas. Uma possível explicação é que aeronaves de menor porte — especialmente as da aviação geral — dispõem de menor robustez estrutural e sistemas de segurança menos sofisticados, tornando os acidentes mais propensos a desfechos fatais mesmo com impactos de menor intensidade. A transformação logarítmica (PMD_log) captou com maior precisão a distribuição assimétrica da variável, o que explica sua posição de maior destaque em relação ao PMD bruto.

Tabela 3. Estatísticas descritivas do PMD por grupo de desfecho.

Estatística	Sem Fatalidade (n = 4.084)	Com Fatalidade (n = 792)
Média (kg)	3.777,9	2.244,7
Desvio padrão (kg)	14.314,3	5.210,1
Mediana (kg)	1.633,0	1.542,0
Mínimo (kg)	0,0	0,0
Máximo (kg)	346.544,0	79.000,0

Valores em kg.




Figura 6. Distribuição do log(PMD) por grupo de desfecho (Fatalidade = 0 vs. Fatalidade = 1).

A análise da variável Ocorrência Crítica — que indica se o acidente ocorreu durante uma fase operacionalmente crítica do voo (pouso, decolagem, subida, aproximação ou corrida após pouso) — revelou um resultado aparentemente contraintuitivo: acidentes ocorridos em fases não críticas apresentaram proporção de fatalidades aproximadamente quatro vezes maior (~26,5%) do que os ocorridos em fases críticas (~8,0%). Embora o volume absoluto de acidentes seja maior nas fases críticas, a gravidade dos eventos que ocorrem fora delas é sistematicamente superior. Uma explicação possível é que acidentes em fases críticas frequentemente envolvem velocidades menores e proximidade de estruturas de apoio, o que favorece a sobrevivência. Em contraste, acidentes ocorridos durante o cruzeiro — a principal fase não crítica — tendem a envolver aeronaves em altitude, com energia cinética elevada e menor possibilidade de recuperação, resultando em maior severidade do desfecho.

Tabela 4. Proporção de fatalidades por fase crítica da operação.

Ocorrência Crítica	Sem Fatalidade (%)	Com Fatalidade (%)
Não (0)	73,7%	26,3%
Sim (1)	91,7%	8,3%

A análise do Tipo de Ocorrência revelou ampla variação nas taxas de fatalidade entre as categorias. O tipo UNK (desconhecido) apresentou a maior proporção de desfechos fatais, com aproximadamente 53% dos acidentes dessa categoria resultando em vítimas. Uma interpretação possível é que acidentes de extrema severidade causam danos tão extensos à aeronave que dificultam a identificação da ocorrência original, levando à classificação como desconhecida. A Perda de Controle em Voo (LOC-I) também registrou taxa de fatalidade

elevada (~42,5%), o que pode ser atribuído ao fato de que a perda de controle ocorre geralmente em voo, em altitude, com tempo de recuperação limitado para a tripulação. O tipo CTOL (Colisão com Obstáculo durante Decolagem ou Pouso) apresentou taxa de aproximadamente 25%, associada a impactos com obstáculos físicos — como árvores, torres e edificações — que podem comprometer estruturalmente a aeronave mesmo em velocidades relativamente baixas.

Tabela 5. Taxa de fatalidade por tipo de ocorrência (ordenada da maior para a menor).

Tipo de Ocorrência	Taxa de Fatalidade (%)
UNK	53,4%
LOC-I	42,5%
Desconhecido	29,9%
CTOL	24,2%
OUTROS	17,1%
OTHR	15,3%
SCF-PP	9,1%
SCF-NP	6,6%
LOC-G	1,9%
RE	1,4%

Do ponto de vista aplicado, o modelo tem potencial para subsidiar sistemas de triagem preventiva em órgãos como o CENIPA e a ANAC: dada a notificação de uma ocorrência, o modelo poderia sinalizar automaticamente os casos com maior probabilidade de desfecho fatal, priorizando a alocação de equipes de resposta e inquérito. A escolha do *threshold* mais adequado fica condicionada ao objetivo da aplicação: contextos de triagem emergencial demandam maior recall (*threshold* mais baixo), enquanto contextos de alocação de recursos escassos podem priorizar maior precisão (*threshold* mais alto).

4. Conclusão

Este estudo demonstrou que é possível construir, a partir dos dados públicos da Agência Nacional de Aviação Civil (ANAC), um modelo preditivo com utilidade prática para identificar acidentes aeronáuticos brasileiros com risco de desfecho fatal. Utilizando o algoritmo Random Forest sobre 5.158 ocorrências registradas no território nacional, o modelo alcançou ROC-AUC = 0,872, indicando forte capacidade discriminatória global, e PR-AUC = 0,530 — aproximadamente três vezes superior ao *baseline* aleatório de 0,178, o que confirma poder preditivo relevante mesmo diante do severo desbalanceamento de classes (83,4% vs. 16,6%). Com o *threshold* de referência de 0,45, o modelo identificou corretamente 82% dos acidentes fatais (Recall = 0,82) mantendo Precision = 0,41, com F1-score = 0,54. Dos 184 eventos fatais no conjunto de teste, apenas 34 não foram detectados (falsos negativos), enquanto 150 foram corretamente sinalizados. A distribuição das probabilidades preditas evidenciou separação visual entre as classes, confirmando a capacidade do modelo de distinguir ocorrências fatais das não fatais a partir de características operacionais, geográficas e técnicas disponíveis nos registros públicos da ANAC.

Do ponto de vista teórico, os resultados reforçam a adequação do Random Forest para problemas de classificação em dados de segurança aeronáutica e são consistentes com a literatura internacional. Siow (2025) reportou F1-score de 0,78 com o mesmo algoritmo sobre

dados australianos, enquanto Ramadhan et al. (2025) obtiveram acurácias próximas a 80% em análise de 75 anos de registros globais. O desempenho competitivo obtido exclusivamente sobre dados brasileiros corrobora o argumento de Omrani et al. (2024) de que modelos contextualizados por país tendem a superar modelos globais, evidenciando a relevância de desenvolver soluções preditivas nacionais mesmo quando o volume de dados é menor. O estudo também contribui à literatura ao demonstrar que a estratégia *class_weight = 'balanced'* constitui alternativa eficaz ao SMOTE (Chawla et al., 2002) para o tratamento de desbalanceamento severo de classes em dados de acidentes, sem introduzir amostras sintéticas que possam distorcer a distribuição original dos dados.

Do ponto de vista prático, o modelo tem potencial imediato para subsidiar sistemas de triagem preventiva em órgãos como o CENIPA e a ANAC. Diante da notificação de uma ocorrência, o sistema poderia sinalizar automaticamente os casos com maior probabilidade de desfecho fatal, priorizando a alocação de equipes de investigação e socorro. A flexibilidade no ajuste do *threshold* torna o modelo adaptável a diferentes objetivos operacionais: em contextos de triagem emergencial, um limiar mais baixo (0,39; Recall = 0,87) maximiza a detecção de eventos fatais mesmo ao custo de mais falsos positivos; em contextos de alocação de recursos escassos, um limiar mais elevado (0,51; Precision = 0,44) reduz intervenções desnecessárias. Para formuladores de políticas públicas, os resultados oferecem base empírica para fundamentar regulamentações preventivas direcionadas aos perfis operacionais de maior risco identificados pelo modelo — como tipo e porte da aeronave, fase crítica da operação e região geográfica —, substituindo abordagens reativas por uma gestão de segurança orientada por dados.

No que diz respeito às limitações, algumas considerações merecem destaque. Do ponto de vista dos dados, a base da ANAC restringe-se a ocorrências registradas no território brasileiro e pode apresentar sub-registro, especialmente para operações de aviação geral e de pequeno porte em regiões remotas. Variáveis potencialmente relevantes — como condições meteorológicas no momento do acidente, experiência da tripulação e histórico de manutenção da aeronave — não estão disponíveis nos dados públicos, o que limita o poder explicativo do modelo. Do ponto de vista metodológico, a importância das variáveis calculada via MDI (*Mean Decrease in Impurity*) tende a superestimar a relevância de variáveis com alta cardinalidade; estudos futuros deverão complementar essa análise com valores de Shapley (SHAP) para interpretação mais robusta das contribuições individuais. Adicionalmente, o modelo não foi submetido a validação cruzada aninhada na etapa de seleção de hiperparâmetros, o que pode introduzir viés otimista nas estimativas de desempenho reportadas. Também foi realizada uma análise exploratória com modelos treinados separadamente por década de ocorrência (anos 2000, 2010 e 2020), porém os resultados foram insatisfatórios — F1-score não superior a 0,40 em nenhum dos estratos —, possivelmente em razão da insuficiência de observações por subperíodo; essa abordagem não foi incluída no estudo, mas indica que análises temporais estratificadas requerem bases de dados mais extensas. Por fim, a generalização dos resultados para outros países ou períodos distintos do coberto pela base requer cautela, dadas as especificidades regulatórias e operacionais da aviação civil brasileira.

Com base nos achados e limitações identificados, recomenda-se, para trabalhos futuros, a incorporação de dados meteorológicos — como os disponibilizados pelo Instituto Nacional de Meteorologia (INMET) — ao conjunto de preditores, enriquecendo a capacidade explicativa do modelo. A comparação direta com algoritmos de *gradient boosting* (LightGBM, CatBoost) e redes neurais é recomendável para avaliar possíveis ganhos de desempenho além dos obtidos com o XGBoost neste estudo. Para pesquisadores da área, sugere-se a extensão do modelo para classificação multinível de gravidade (ileso, leve, grave, fatal) ou para a previsão do tipo de

ocorrência, ampliando o escopo da análise preditiva. A profissionais e gestores públicos do setor aeronáutico, recomenda-se que o modelo sirva como ponto de partida para o desenvolvimento de sistemas de apoio à decisão integrados aos fluxos já existentes de notificação do CENIPA, com atualização periódica à medida que novos dados se tornem disponíveis.

Em síntese, este trabalho demonstra que técnicas de aprendizado de máquina aplicadas a dados abertos governamentais podem contribuir de forma concreta e mensurável para o avanço da segurança aeronáutica no Brasil. A combinação de engenharia de variáveis contextualizada, tratamento adequado do desbalanceamento de classes e avaliação por métricas apropriadas ao problema resultou em um modelo preditivo robusto, interpretável e com potencial de aplicação real. O acesso público à base de dados da ANAC garante plena replicabilidade do estudo e abre caminho para aprimoramentos progressivos — seja pela incorporação de novas fontes de dados, seja pela adoção de técnicas mais avançadas de interpretação e calibração. Espera-se que os achados aqui apresentados incentivem outros pesquisadores, reguladores e gestores públicos a investir em abordagens orientadas por dados para a prevenção de acidentes aeronáuticos no país, contribuindo para um sistema de aviação civil mais seguro e eficiente.

Referências

- ANAC. (2023). *Dados abertos de ocorrências aeronáuticas*. Agência Nacional de Aviação Civil. Recuperado de <https://www.gov.br/anac/pt-br/dados-abertos>
- Baugh, B. S. (2020). *Predicting general aviation accidents using machine learning algorithm* [Doctoral dissertation, Embry-Riddle Aeronautical University]. ERAU Scholarly Commons. <https://commons.erau.edu/edt/545>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Caetano, M. (2023). Aviation accident and incident forecasting combining occurrence investigation and meteorological data using machine learning. *Aviation*, 27(1), 47–56. <https://doi.org/10.3846/aviation.2023.18641>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- İnan, T. T., & Gökmen İnan, N. (2022). The analysis of fatal aviation accidents more than 100 dead passengers: An application of machine learning. *OPSEARCH*, 59(4), 1377–1395. <https://doi.org/10.1007/s12597-022-00585-1>
- Madeira, T., Melício, R., Valério, D., & Santos, L. (2021). Machine learning and natural language processing for prediction of human factors in aviation incident reports. *Aerospace*, 8(2), 47. <https://doi.org/10.3390/aerospace8020047>
- Omrani, F., Etemadfar, H., & Shad, R. (2024). Assessment of aviation accident datasets in severity prediction through machine learning. *Journal of Air Transport Management*, 115, 102531. <https://doi.org/10.1016/j.jairtraman.2023.102531>
- Ramadhan, R., Kusuma, A. A., & Raharjo, S. (2025). AI-based prediction of fatalities in flight accidents: Insights from 75 years of aviation accident records. *Indonesian Journal of Artificial Intelligence and Data Mining*, 8(1). <https://doi.org/10.24014/ijaidm.v8i1.37948>

- Siow, B. Y. (2025). *A practical approach to using supervised machine learning models to classify aviation safety occurrences* [Preprint]. arXiv.
<https://arxiv.org/abs/2504.09063>
- Silva, F. U. S. (2026). *Um modelo preditivo de fatalidade em acidentes aeronáuticos no Brasil: Random Forest aplicado a dados da ANAC*. Trabalho apresentado no congresso [a confirmar]. Departamento de Estatística, Universidade Federal de Pernambuco.